Rapporto Finale

Gruppo MielPops - Gaetano Bonofiglio, Veronica Iovinella

Job 1

Pseudocodifica

Map-Reduce

Nella Map è stata creata una coppia in cui il primo valore è un tipo di dato composto da anno, mese e prodotto, mentre il valore è lo score.

La Reduce accumula i risultati in un dizionario ordinato che ha come chiave la coppia mese e anno e come valore un array ordinato per average score di 5 prodotti e il loro score medio. Per permettere di scalare, nel codice Java, è stato definito un **Partitioner** sulla base del range degli anni, che determina anche il numero di Reducer. La Cleanup del Reducer emette i dati contenuti nel dizionario.

```
Map(key, record):
    newKey = month + year + prodID
    emit (newKey, score)
create global OrderedMap<year+month, (avg, prodId)> results

Reduce(key, records):
    create Array[5] top5
    month, year, prodId = key.getData()
    foreach score in records:
        totalScore += score
        totalCount++
    avg = totalScore / totalCount
    newKey = month + year
    value = (avg, prodId)
    top5.insertInOrderByAvg(value)
    results.insert(newKey, top5)
CleanUp():
    foreach newKey, value in results
        emit (newKey, value)
```

Hive

Vengono inizialmente selezionati i prodotti e il loro score medio, raggruppati per mese e anno. Viene dunque aggiunto un campo che contiene il numero della riga per quel mese e anno, ordinando il numero in base allo score medio più alto. L'ultima selezione taglia le righe quando la loro numerazione supera 5 e raggruppa i prodotti in una lista.

```
SELECT mpl.month, COLLECT_LIST(mpl.product_id), COLLECT_LIST(mpl.avg_score)
FROM
(   SELECT mp.month, mp.product_id, mp.avg_score, row_number() OVER (PARTITION BY
mp.month ORDER BY mp.avg_score DESC) AS top_position
    FROM
  (   SELECT FROM_UNIXTIME(time,'yyyyMM') AS month, product_id, AVG(score) AS avg_score
    FROM 1999_2006
    GROUP BY FROM_UNIXTIME(time,'yyyyMM'), product_id
    ORDER BY month ASC ) mp
  ORDER BY mp.avg_score DESC) mpl
WHERE mpl.top_position <= 5
GROUP BY mpl.month;
```

Spark

Si mappa inizialmente il dataset in una coppia in cui la chiave è mese + anno + prodotto e il valore è una coppia score e la costante 1. Vengono dunque conteggiati i prodotti di quel mese sfruttando la costante e successivamente calcolate le medie e raggruppate in un nodo per ottenere la top 5 ordinata.

```
results = csv
        .mapToPair(month + product, (score, 1))
        .reduceByKey((scoreA + scoreB, countA + countB))
        .mapToPair(month, average)
        .groupByKey(1 node)
        .mapToPair(month, iterable.getTop5()).sortByKey(true)
```

Output (prime 10 righe)

input 1999_2006.csv:

```
1999    10      (0006641040, 5.0)

1999    12      (B00004CI84, 5.0)  (B00004CXX9, 5.0)  (B00004RYGX, 5.0)

2000    01      (B00002N8SM, 5.0)  (B00004CXX9, 3.6666667)    (B00004CI84, 3.0)  (B00004RYGX,
3.0)

2000    02      (B00004CI84, 4.0)  (B00004CXX9, 4.0)  (B00004RYGX, 4.0)

2000    06      (B00002Z754, 5.0)  (B00004CI84, 5.0)  (B00004CXX9, 5.0)  (B00004RYGX, 5.0)

2000    07      (B00004RAMX, 5.0)

2000    08      (B00004CI84, 5.0)  (B00004CXX9, 5.0)  (B00004RYGX, 5.0)  (B00004S1C5, 5.0)
(B00004S1C6, 5.0)

2000    10      (B00004CI84, 5.0)  (B00004CXX9, 5.0)  (B00004RYGX, 5.0)

2000    12      (B00004CI84, 5.0)  (B00004CXX9, 5.0)  (B00004RYGX, 5.0)  (B00004S1C5, 5.0)

2001    02      (B00004S1C6, 5.0)
```

Job 2

Pseudocodifica

Map-Reduce

Similmente al Job 1, la Map emette una coppia in cui la chiave è l'utente e il valore è una coppia score + prodotto. La Reduce accumula i dati in un dizionario ordinato in cui la chiave è l'utente e il valore è un array di 10 coppie prodotto + score, ordinato per score. La Cleanup emette il dizionario. A differenza del Job 1 non serve ridefinire un Partitioner perché quello di default va già bene, per scalare è quindi data all'utente la possibilità di scegliere il numero di Reducer.

```
Map(key, record):
    value = (score, prodId)
    emit (userID, value)
create global OrderedMap<userId, (score, prodId)> results
Reduce(key, records):
    create Array[10] top10
    for each value in records:
        top10.insertInOrderByScore(value)
    results.insert(key, top10)
CleanUp():
    for each key, value in results
        emit (key, value)
```

Hive

Una prima selezione ottiene utente, prodotto e score, ordinando per utente e contando le righe con quell'utente in base allo score più alto. La seconda selezione taglia via le righe con numero maggiore di 10 e raggruppa i prodotti in una lista per ogni utente.

```
SELECT ups.user_id, COLLECT_LIST(ups.product_id), COLLECT_LIST(ups.score)
FROM
(   SELECT user_id, product_id, score, row_number() OVER (PARTITION BY user_id ORDER BY
score DESC) AS top_position
    FROM 1999_2006
  ORDER BY score DESC) ups
WHERE ups.top_position <= 10
GROUP BY ups.user_id
ORDER BY ups.user_id ASC;
```

Spark

Viene mappata ogni riga in una coppia in cui la chiave è l'utente e il valore è una coppia score + prodotto. Vengono dunque raggruppati i risultati e sono selezionati i top 10 prodotti.

```
results = csv
        .mapToPair(userId, (score, productId))
        .groupByKey(1 node)
        .mapToPair(userId, iterable.getTop10()).sortByKey(true)
```

Output (prime 10 righe)

input 1999_2006.csv:

```
A100CY9WRC18I2   (B000CQG84Y, 1)
A101CCC619GN4S   (B00017L1UK, 5)
A101VS17YZ5ZEJ   (B0004LW990, 5)
A103OZ75AVET1Y   (B000CBOR60, 5)
A1048CYU0OV4O8   (B00004RYGX, 5)  (B00004CI84, 5)  (B00004CXX9, 5)
A105981PIJDJUU   (B000FFLHSY, 4)
A106E0DP6X12NW   (B0007NOWMM, 1)  (B0001ES9F8, 1)
A106MCEFKHCTX9   (B000DZFMEQ, 5)
A106X6HMD3NE76   (B0002QEKPI, 5)
A107OAJUDTZXTC   (B000FDMLUO, 5)  (B0007SNZQ6, 5)  (B000CROPGQ, 2)
```

Job 3

Pseudocodifica

Di seguito sono proposte due versione di Map-Reduce: la prima è costruita con due task, e ciò permette di scalare meglio grazie al fatto che è possibile indicare più reducer nel secondo task, mentre la seconda è costruita con un solo task ma che richiede molta più memoria.

La prima Map emette coppie product e score qualora quest'ultimo fosse maggiore o uguale a 4. La prima Reduce scorre in modo annidato i valori ottenuti dalla Map confrontando ogni utente con quelli successivi. A questo punto emette una coppia ordinata di utenti ed il prodotto in ogni iterazione, verificando che i due utenti siano diversi. La seconda Map riprende come chiave la coppia di utenti e come valore il prodotto. La seconda Reduce ha dunque a disposizione la lista di prodotti comuni ai due utenti con score maggiore o uguale a 4. Se la lista è almeno lunga 3, allora la riga è emessa.

2x MapReduces version

```
Map(key, record):
    if score >= 4:
        emit (prodId, userId)
Reduce(key, record):
    for i=0; i<values.length; i++:
        user1 = values[i]
             for j=i+1; j<values.length; j++:
                user2 = values[j]
      if user1 != user2:
        newKey = orderCouple(user1, user2)
        emit (newKey, prodId) //prodId is the old key
Map2(key, record):
    newKey = (user1, user2)
    emit (newKey, prodId)
```

```
Reduce2(key, records):
    if records.length >= 3
        emit (key, records.toString())
```

1x MapReduce, RAM intensive

Questa versione funziona in modo simile alla prima ed all'implementazione dei Job 1 e 2. Al posto di usare una seconda Map-Reduce è utilizzato un dizionario ordinato di appoggio, che poi è elaborato in fase di Cleanup.

```
Map(key, record):
    if score >= 4:
        emit (prodId, userId)

create global OrderedMap<coppia di utenti, lista di prodotti> results

Reduce(key, records):
    for i=0; i<values.length; i++:
        user1 = values[i]
             for j=i+1; j<values.length; j++:
      if user1 != user2:
        user2 = values[j]
        results.insert(value.userId + value2.userId, prodId)
CleanUp():
    for each key, value in results
        if value.lenght >= 3
        emit (key, value)
```

Hive

Una prima selezione fa il join del dataset con se stesso sulla base del prodotto e solo se lo score è maggiore o uguale a 4 e se gli utenti sono diversi tra loro. Vengono dunque usate funzioni di Hive per concatenare i due utenti in una coppia ordinata. Una seconda selezione raggruppa i prodotti per coppia di utenti e vi affianca il conteggio dei prodotti. Vengono dunque selezionati coppia di utenti e lista di prodotti se il conteggio è almeno pari a 3.

```
SELECT upn.user_couple, upn.products
FROM
(       SELECT up.user_couple, COLLECT_LIST(up.product_id) as products, COUNT(1) as
num_products
  FROM
  (     SELECT DISTINCT CONCAT_WS(',', SORT_ARRAY(ARRAY(jr.user_id, jl.user_id))) as
user_couple, jr.product_id
    FROM 1999_2006 jr JOIN 1999_2006 jl ON jr.product_id = jl.product_id AND jr.score
>= 4 AND jl.score >=4
    WHERE jr.user_id != jl.user_id
    ) up
  GROUP BY up.user_couple
  ORDER BY up.user_couple ASC
) upn
WHERE upn.num_products >= 3;
```

Spark

Vengono mappati i risultati in coppie di prodotto e utente + score, filtrando via se lo score è basso. Viene fatto il join dei risultati con loro stessi sul prodotto, filtrando se i 2 utenti sono uguali. La coppia è ordinata alfabeticamente e sono selezionate solo le righe con lista dei prodotti più lunga di 3.

```
userScoreByProduct = csv
        .mapToPair(productId, (userId, score))
        .filter(score >= 4)
results = userScoreByProduct
        .join(userScoreByProduct)
        .filter(user1 != user2)
        .mapToPair(orderCouple(user1, user2), productId)
        .distinct()
        .groupByKey(1 node)
        .filter(productList >= 3).sortByKey(true)
```

Output (prime 10 righe)

input 1999_2006.csv:

```
A1048CYU0OV4O8   A157XTSMJH9XA4   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A19JYLHD94K94D   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1BZEGSNBB7DVS   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1CAA94EOP0J2S   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1CZICCYP2M5PX   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1DU58OZJNPUHV   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1E5AVR7QJN8HF   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1FJOY14X3MUHE   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1GB1Q193DNFGR   [B00004CI84, B00004CXX9, B00004RYGX]
A1048CYU0OV4O8   A1HWMNSQF14MP8   [B00004CI84, B00004CXX9, B00004RYGX]
```

Tempistiche

Tutti i test locali sono stati eseguiti su un container Docker a cui sono stati dedicati 8 GB di memoria e 4 core @ 2.4 GHz, mentre i test sul cluster sono stati effettuati su cluster.inf.uniroma3.it. Map-Reduce e Spark sono stati eseguiti da riga di comando sul Node1, mentre Hive è stato utilizzato dalla UI di Ambari che a sua volta ha delegato i task ad un nodo del cluster aggiungendo più overhead nel caso non venisse scelto il Node1 come resource manager. Sarebbe possibile ridurre i tempi di overhead del Job 1 partizionando la tabella di Hive sulla base di mese e anno, tuttavia l'andamento della curva è risiltato il medesimo.

I tempi di esecuzione su Spark sono stati calcolati partendo dal secondo in cui il nodo ha accettato il task, fino al completamento. **Inoltre sono stati calcolati a seguito della funzione saveAsTextFile** (utilizzando takeSample o take i tempi sarebbero stati inferiori ma non paragonabili agli altri, mentre la collect e l'output a schermo impiega più tempo). I tempi senza collect o la saveAsTextFile sono risultati costanti e privi di interesse.

I tempi di esecuzione di Hive e Map-Reduce sono stati calcolati dal secondo di inizio della prima Map, fino al completamento.

Oltre ai dataset proposti, sono state eseguiti test su due dataset più grandi, il primo ottenuto dall'unione di tutti i dataset, il secondo duplicando il primo. Abbiamo ottenuto quindi un dataset da circa 300 MB e un dataset da circa 600 MB **con molte ripetizioni**.

Job 1

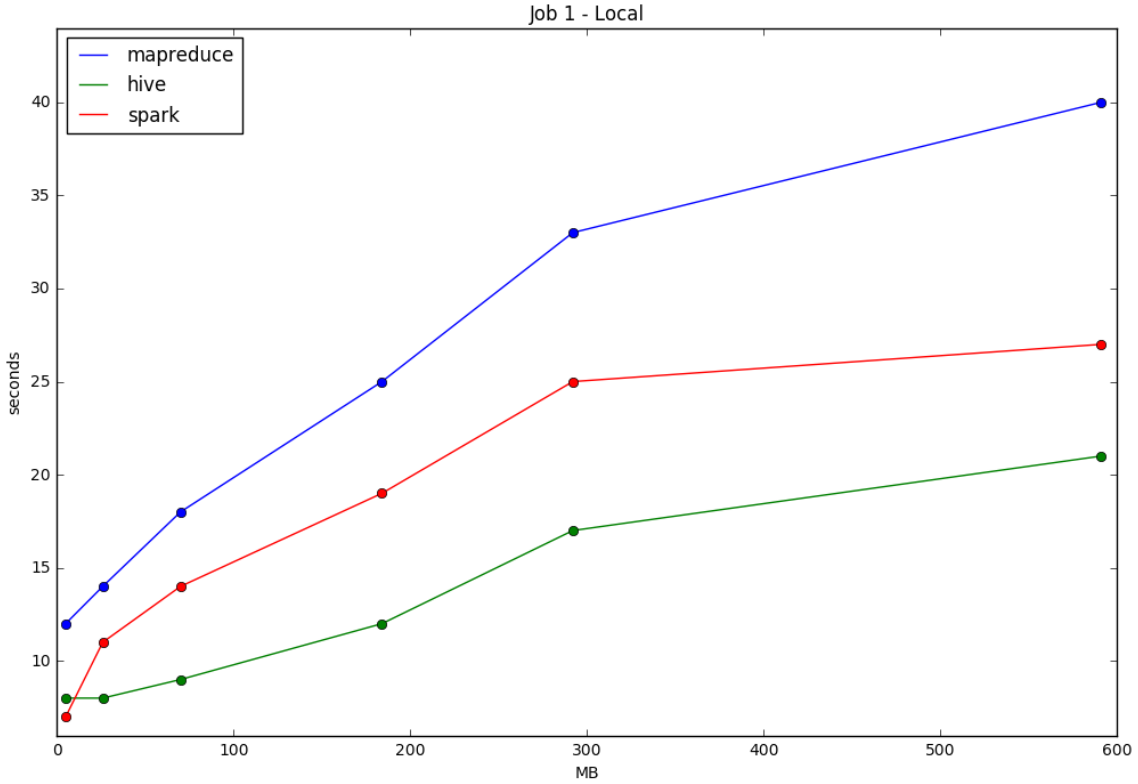
Job 1 - Local
mapreduce
hive
spark
seconds
MB
0
100
200
300
400
500
600
10
15
20
25
30
35
40

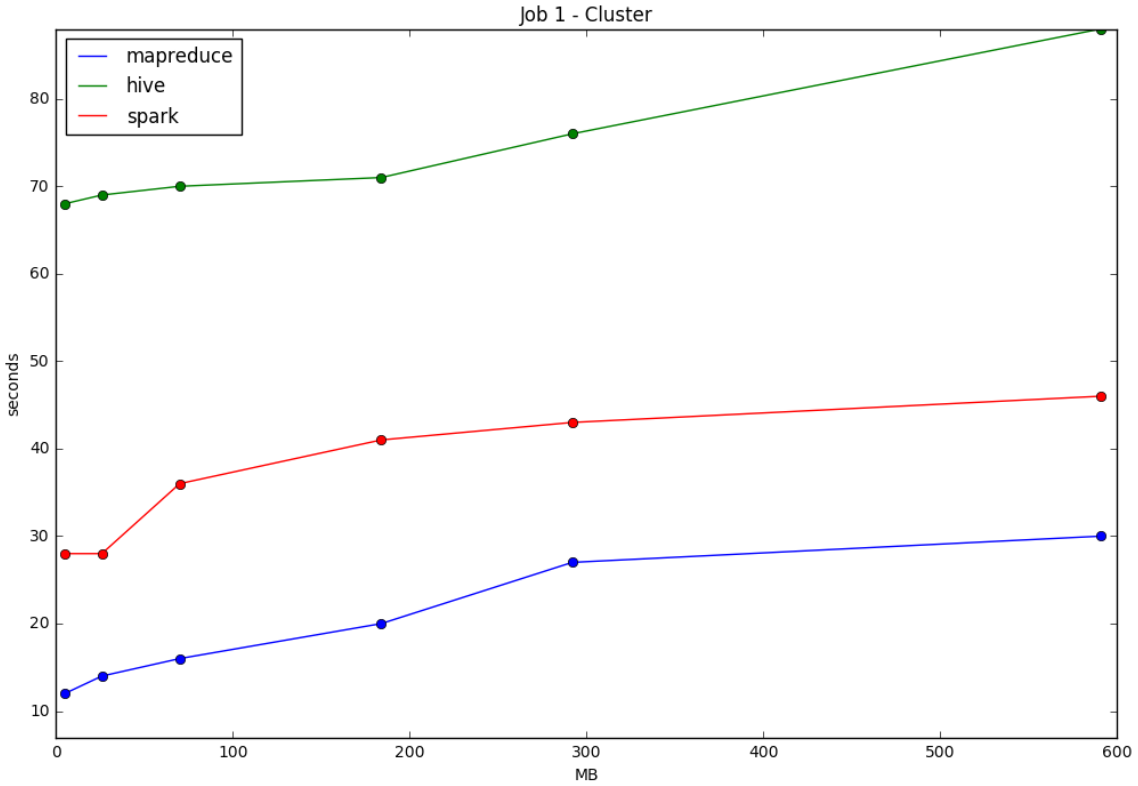
Job 1 - Cluster
mapreduce
hive
spark
seconds
MB
0
100
200
300
400
500
600
10
20
30
40
50
60
70
80

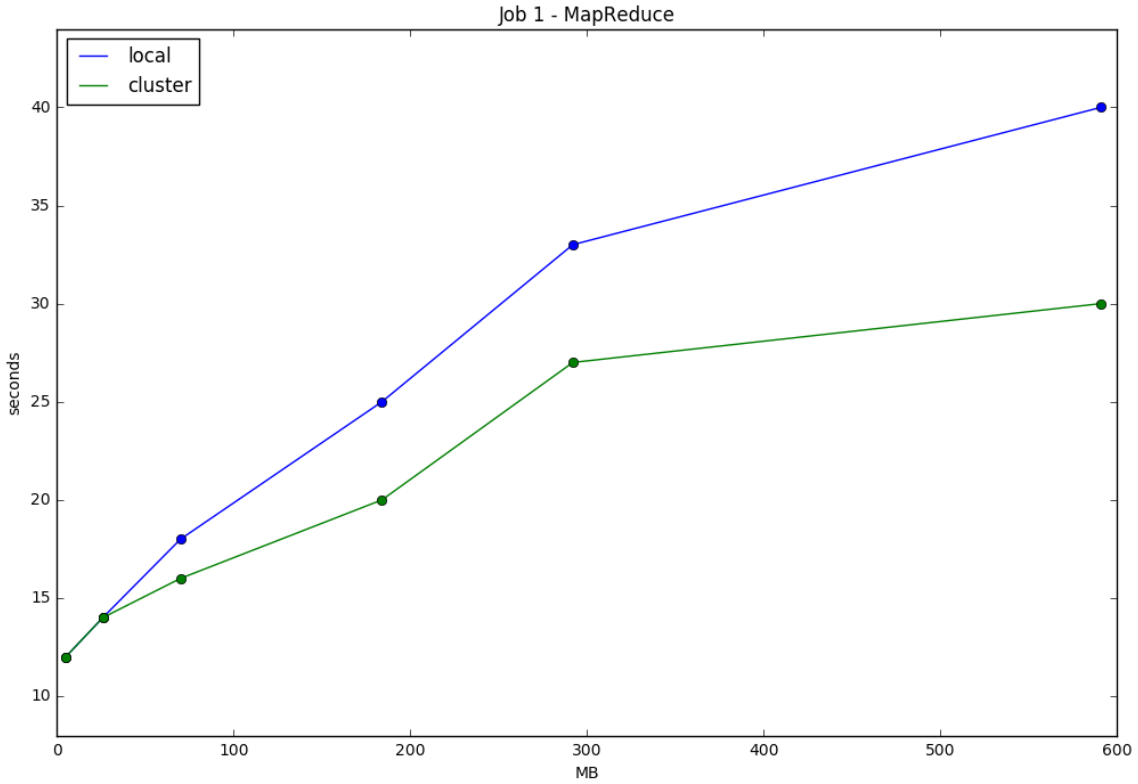

Nei grafici di confronto di Hive e Spark è riportata una terza linea che rappresenta l'andamento su cluster escludendo il tempo di overhead, che può essere influenzato da diversi fattori.

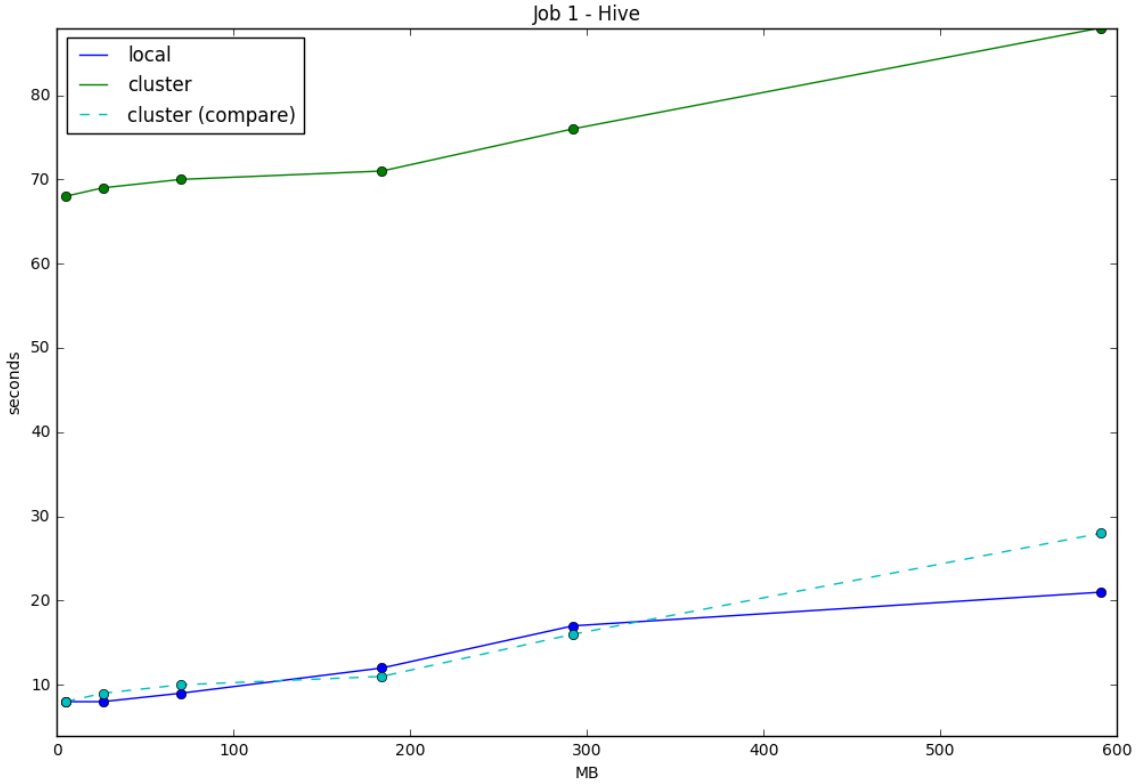

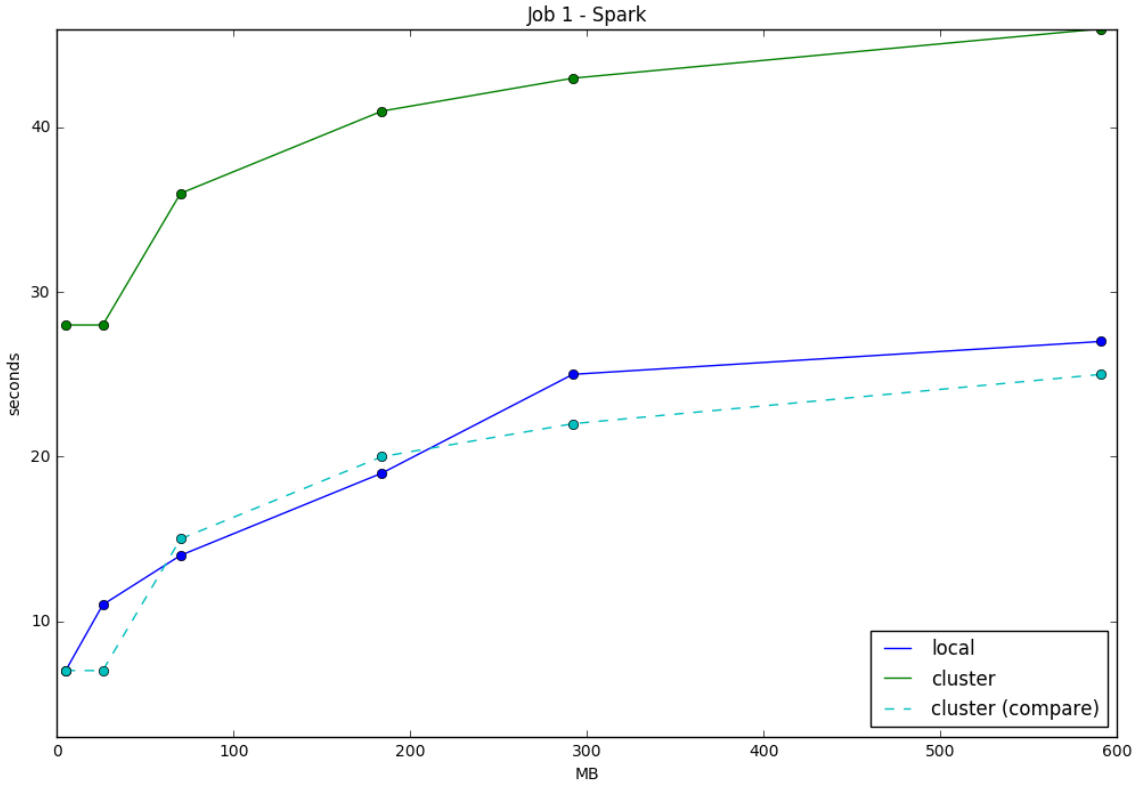
Job 1 - Spark
seconds
MB
local
cluster
cluster (compare)

Job 2

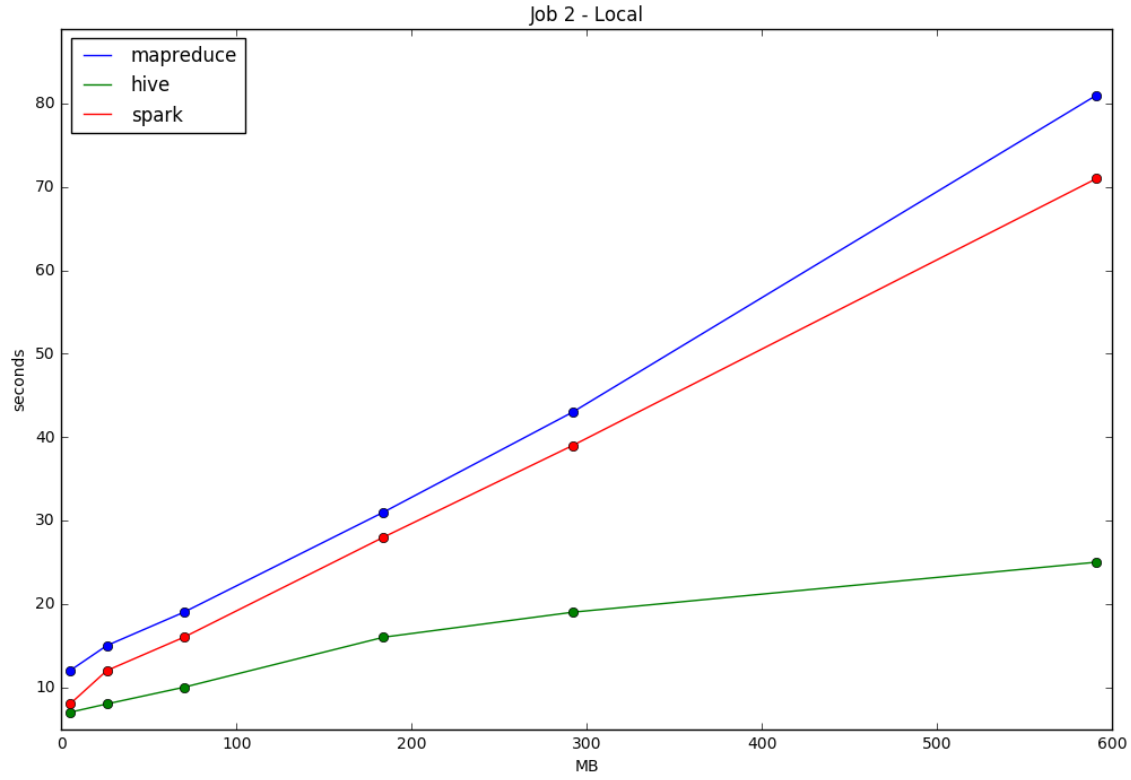
Job 2 - Local
seconds
MB
mapreduce
hive
spark

L'andamento di Hive è caratterizzato dal fatto che nel 5° esperimento (sul dataset da circa 300 MB) il numero di Map allocate è minore e per questo risulta un tempo di overhead minore. È riportata dunque anche una proiezione dell'andamento (linea tratteggiata) escludendo l'outlier.

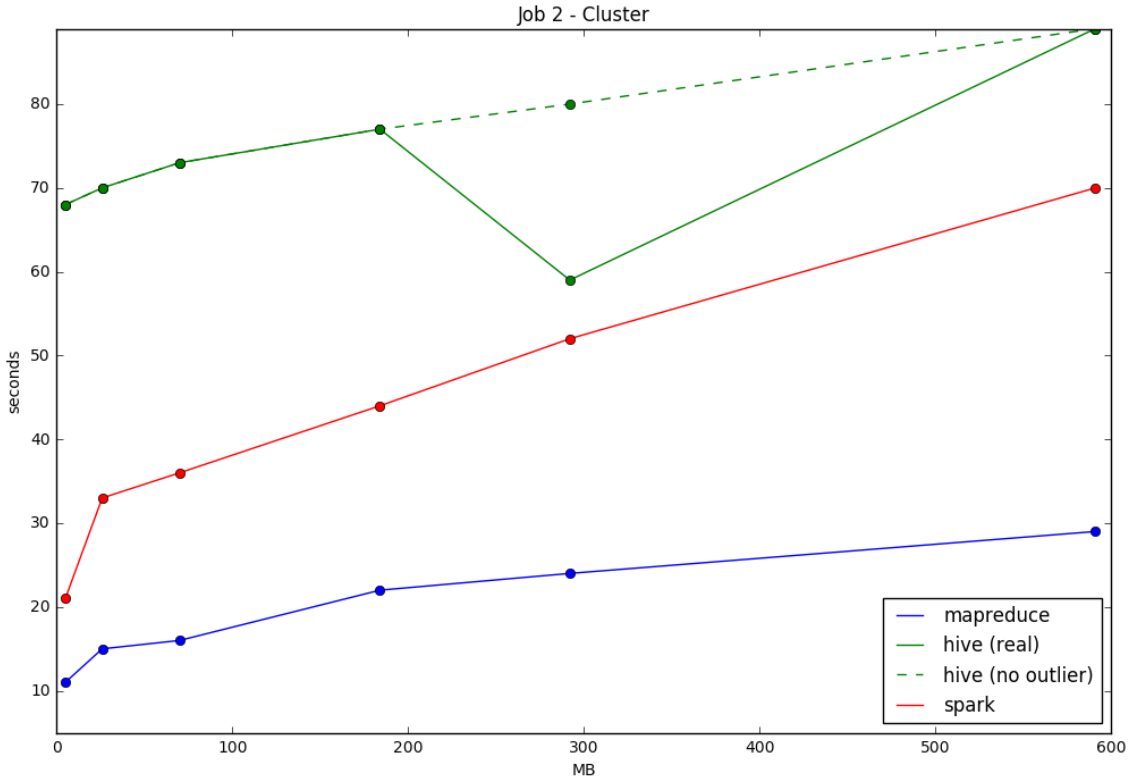

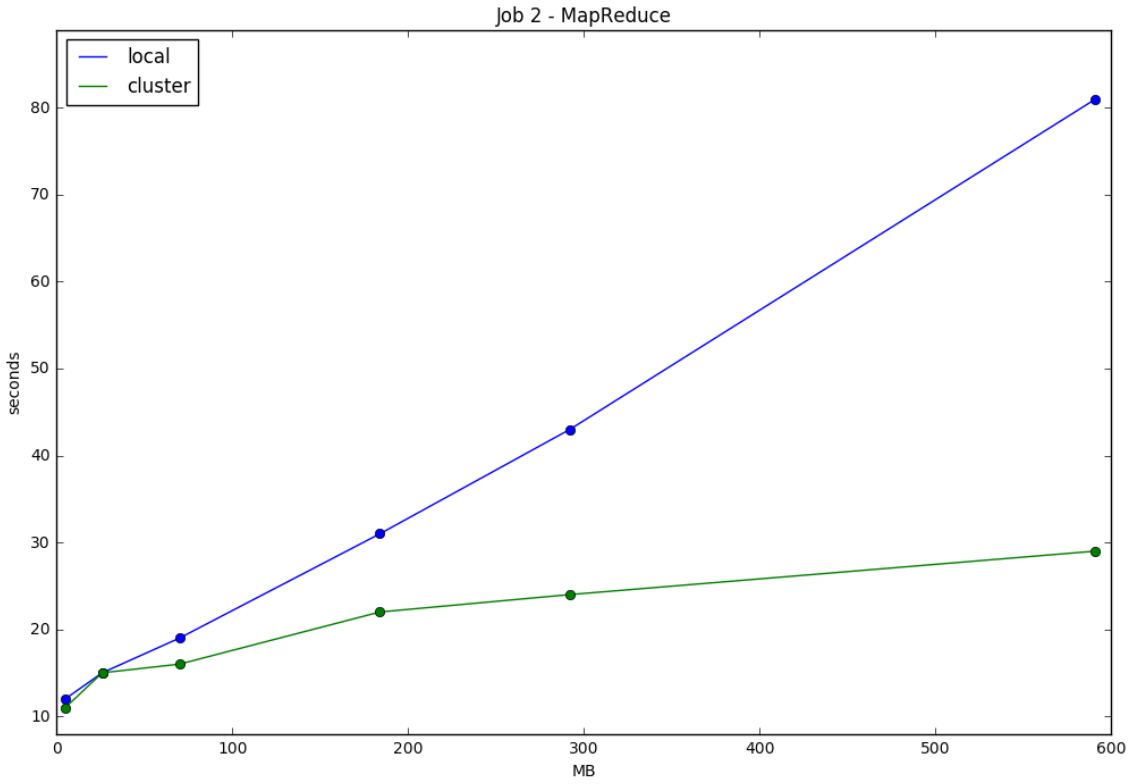

Nel grafico di confronto di Hive è riportata una terza linea che rappresenta l'andamento su cluster escludendo il tempo di overhead.

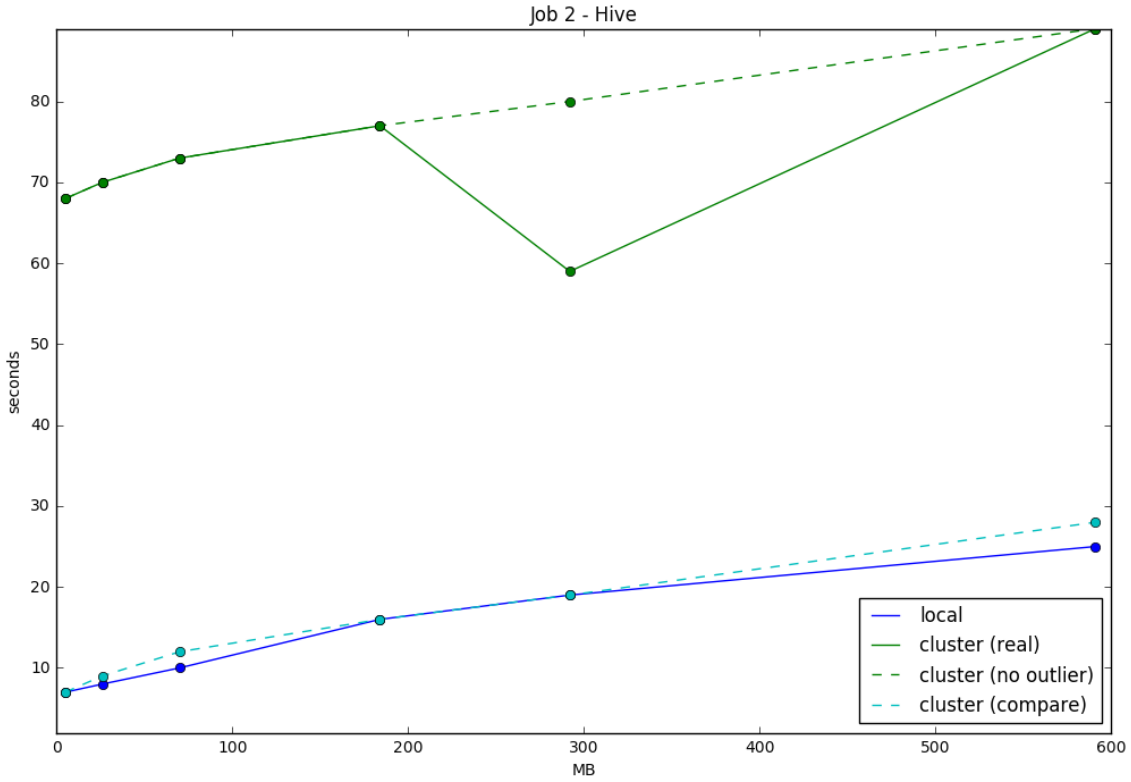

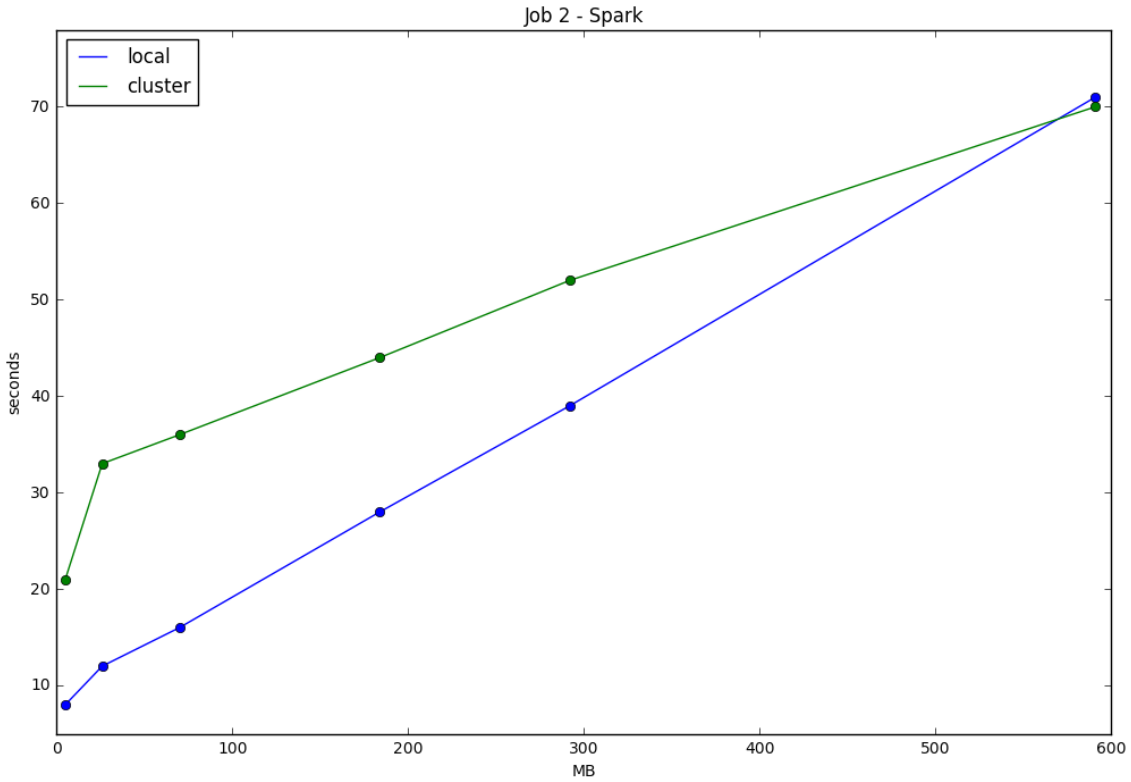

Job 3

Poiché sono state scritte due algoritmi di Map-Reduce per il job 3, di seguito sono riportati gli esperimenti per entrambi gli algoritmi. Per quanto riguarda l'algoritmo RAM intensive, si precisa che sui dataset più grandi (da 300 MB in su) il job falliva sia in locale che su cluster per mancanza di memoria. MapReduce v1 (first), (second) e total sono tempi relativi al primo algoritmo Map-Reduce, mentre MapReduce v2 al secondo.

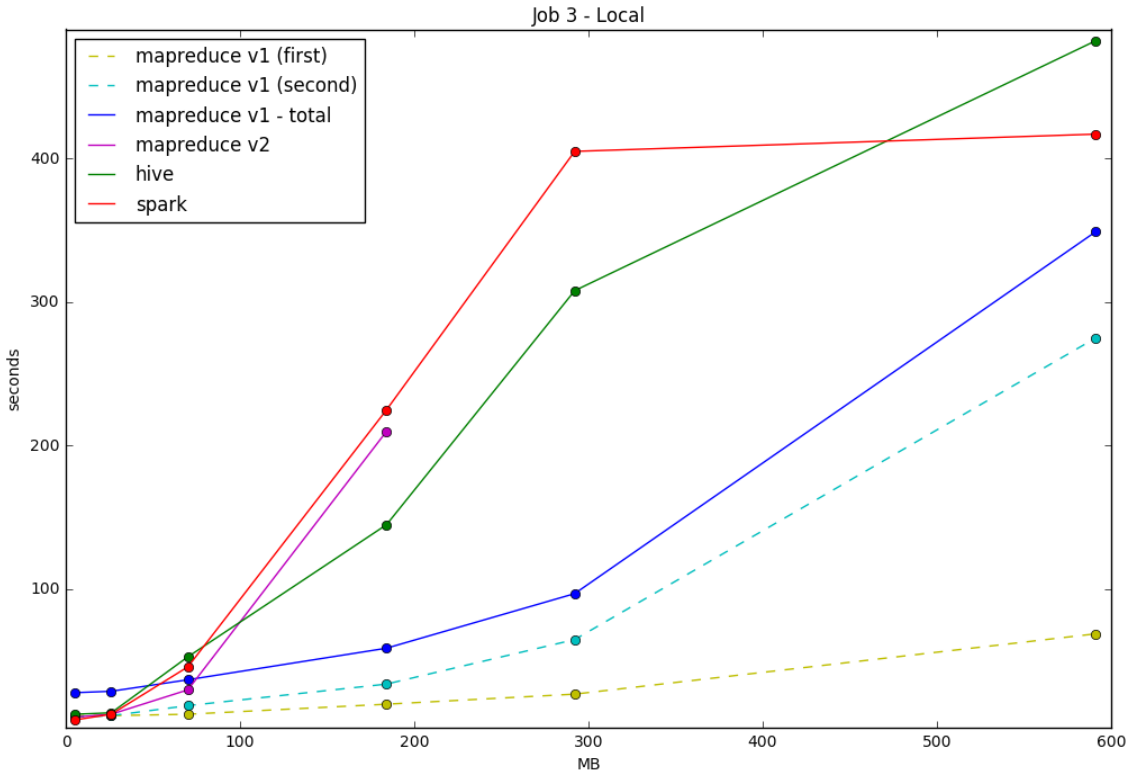

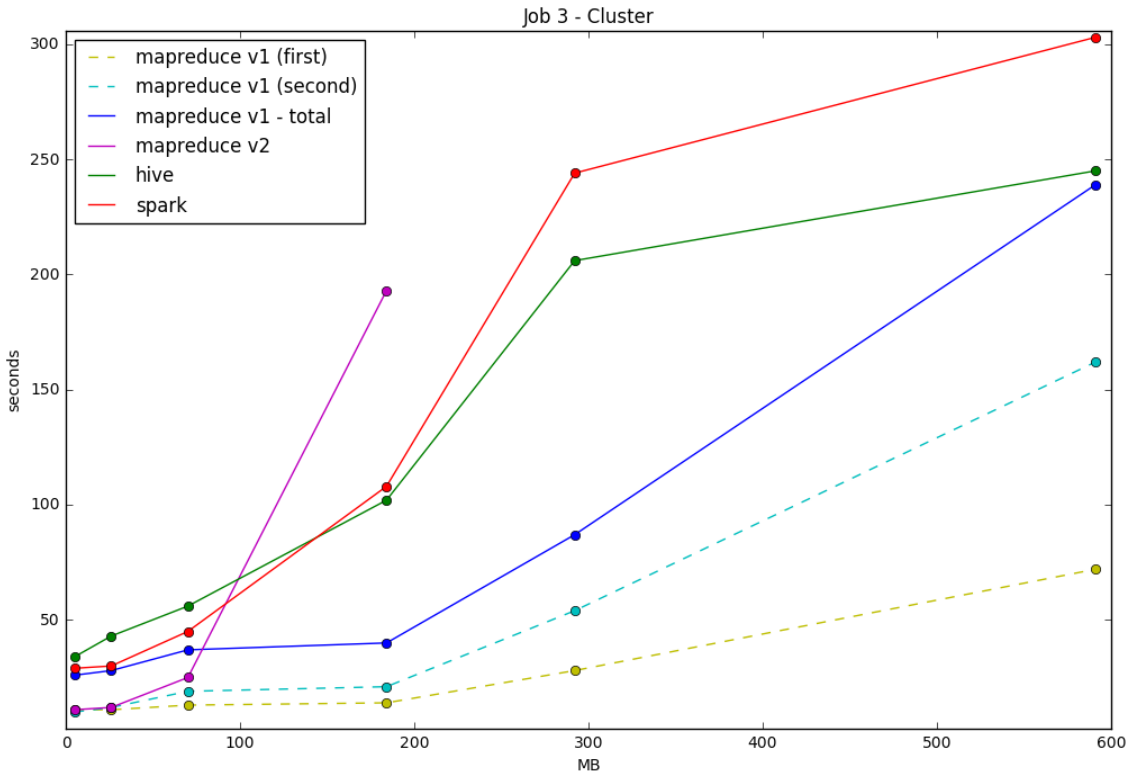

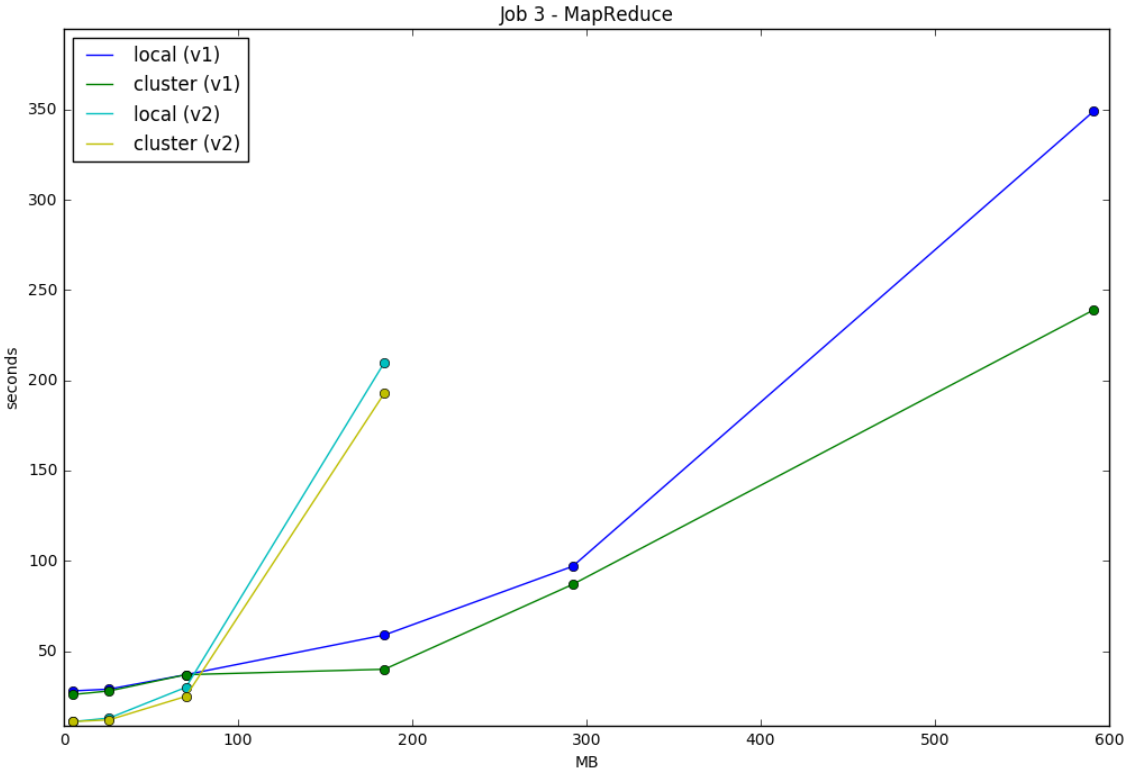
Job 3 - MapReduce
local (v1)
cluster (v1)
local (v2)
cluster (v2)
seconds
MB
0
100
200
300
400
500
600
50
150
250
350

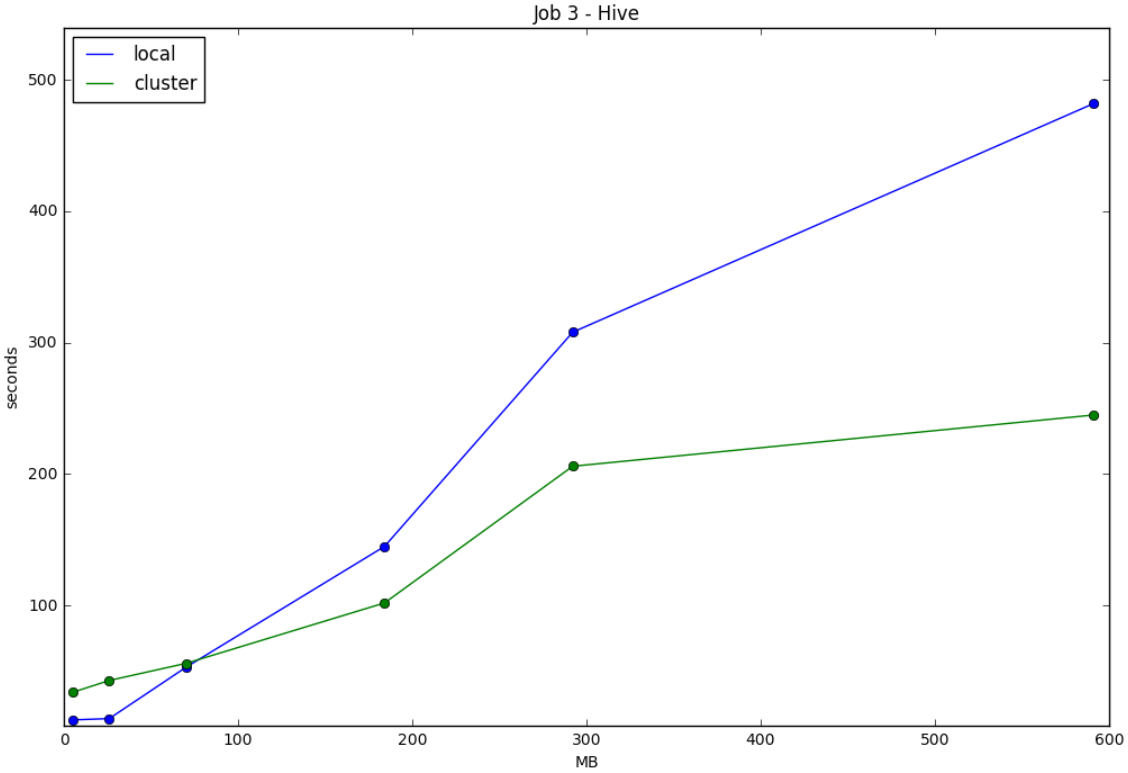
Job 3 - Hive
local
cluster
seconds
MB
0
100
200
300
400
500
600

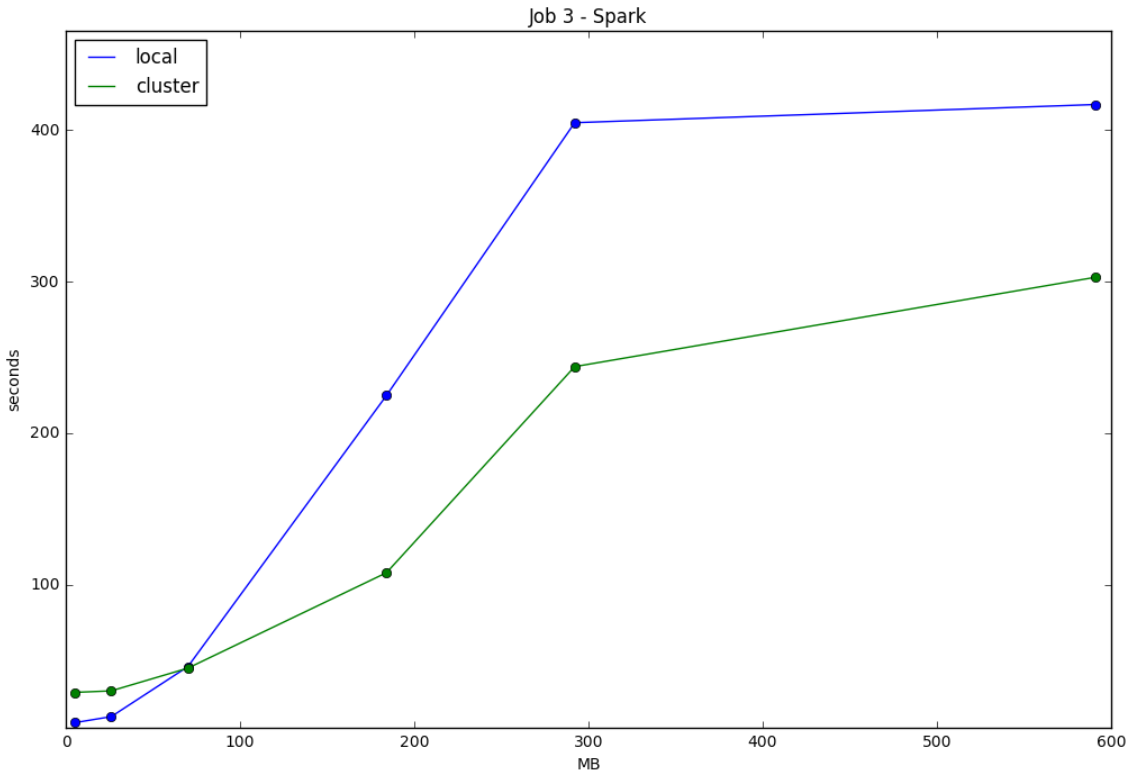

Conclusioni

In generale Hive e Spark si sono comportati meglio di Map-Reduce, soprattutto in cluster dove la disponibilità di RAM è più elevata e riesce a favorire Spark. Quest'ultimo trova difficoltà (e talvolta anche dei failure) solo ad eseguire il Job 3, che prevede un join. In questo caso Hive e Map-Reduce hanno prestazioni generalmente migliori, soprattutto per il dataset più grande. Tutto sommato i risultati, salvo variabilità dei tempi di overhead, sono risultati congrui con le aspettative, anche per quanto riguarda l'ultimo dato raccolto su Spark. Hive ha un sorpreso su cluster, riuscendo a generare molte task Map-Reduce (fino a 60 Map e 20 Reduce per un solo job), utilizzando molto bene le risorse. Map-Reduce si è principalmente rivelato migliore in locale, dove lo sfruttamento possibile di risorse era comunque limitato, e l'ha spuntata il maggior controllo sulle operazioni.